

ENTERPRISE

사내 문서 AI 챗봇 구축 로드맵

대기업 보안 환경 | 최소 비용 | RAG 기반 문서 Q&A 시스템



대상
프로그래밍 초보자



기간
약 14~18주



목표
사내 챗봇 구축·배포

전체 로드맵 한눈에

4단계 · 약 14~18주 · 초보자 → 사내 챗봇 배포

01

3~4주

필수 기초

Python 속성
LLM 이해
프롬프트 설계

02

4~5주

RAG 핵심

문서 처리
벡터 DB
RAG 체인 구축

03

3~4주

보안 전략

온프레미스 LLM
접근 제어
보안 아키텍처

04

4~5주

제품화

웹 UI 개발
품질 평가
운영·확장



STAGE 1

필수 기초 스킬 — 빠르게 압축

3~4주 | 사내 챗봇 구축에 필요한 것만 학습



Python 핵심 속성

- 변수, 리스트, 딕셔너리, 함수 기초
- 파일 읽기/쓰기 (txt, pdf, docx 처리)
- pip 패키지 설치 및 가상환경 관리
- API 호출 기초 (requests 라이브러리)

🔗 산출물: PDF/DOCX 파일 텍스트 추출 스크립트



LLM & 프롬프트 엔지니어링

- LLM 작동 원리 (토큰, 컨텍스트 윈도우)
- 프롬프트 설계 (System, Few-shot, CoT)
- API 사용법 (OpenAI / Anthropic)
- 환각(Hallucination) 문제와 대응 전략

🔗 산출물: 프롬프트 기법별 Q&A 품질 비교 실험

STAGE 2

RAG 파이프라인 핵심 기술

4~5주 | 사내 문서 챗봇의 핵심 엔진



문서 처리 & 임베딩

PDF/DOCX/HWP 파서 → 청킹 전략 (고정/의미 단위) → 임베딩 모델 (한국어 최적)



벡터 DB & 검색 시스템

Chroma (로컬, 보안 최적) → 유사도/하이브리드 검색 → 메타데이터 필터링



RAG 체인 & 프롬프트 최적화

Retrieval → Augment → Generate → Re-ranking → Multi-query/Self-RAG 패턴

RAG 흐름도



STAGE 3

기관 보안 & 온프레미스 전략

| 기관 데이터가 외부로 나가지 않는 구조 설계



온프레미스 LLM 배포

- 오픈소스 LLM 선택 (Llama 3, EXAONE 등)
- 양자화로 GPU 요구사항 절감 (GGUF, GPTQ)
- Ollama / vLLM으로 로컬 추론 서버 구축
- GPU 없이 CPU 추론 시작하기 (llama.cpp)



보안 아키텍처 설계

- 데이터 등급별 처리 정책 (공개/대외비/기밀)
- SSO 연동 + 부서별 문서 접근 제어
- 질문/응답 로그 감사 + 개인정보 마스킹
- 네트워크 격리 + API 프록시 설계

STAGE 4

제품화 & 사내 배포

4~5주 | 프로토타입을 실제 사내 서비스로 전환



웹 UI & API 서버

- FastAPI 백엔드 (스트리밍, 세션)
- Streamlit MVP 또는 React 채팅 UI
- 파일 업로드 + 피드백 수집



평가 & 품질 관리

- RAGAS 자동 평가 파이프라인
- 사용자 A/B 테스트 설계
- 오답 분석 → 개선 사이클



운영 & 확장

- Docker 컨테이너화
- 사내 문서 시스템 자동 동기화
- 모니터링 (응답시간, 에러율)

시스템 아키텍처

온프레미스 RAG 기반 · 모든 데이터가 사내에서만 처리



사용자 (웹 채팅 UI)



API 서버 (FastAPI + 인증)



RAG 엔진 (LangChain)



벡터 DB (Chroma/Milvus)



LLM (Ollama · 온프레미스)



데이터 (문서 파서 + 임베딩)



보안 경계

사내 네트워크
내부에서만
데이터 처리

SSO 인증
접근 제어
감사 로깅

비용 전략: 0원에서 시작

구성 요소	비용	비고
오픈소스 LLM (Llama 3)	무료	자체 서버 GPU 필요
Ollama 추론 서버	무료	설치형, 관리 용이
Chroma 벡터 DB	무료	로컬 설치, 보안 최적
LangChain / LlamaIndex	무료	오픈소스 프레임워크
GPU 서버	기존 인프라	RTX 4090 1장이면 시작 가능

단계별 확장 전략

1

PoC (0원)

개인 PC에서 Ollama + Chroma로
개념 검증

2

파일럿

사내 GPU 서버 활용 → 팀 단위 테스트 운영

3

전사 확대

성과 입증 → 전용 인프라 예산 확보 → 롤아웃